

Practica 8

Análisis Exploratorio y Transformación de la Distribución Salarial en Datos del CPS 1985

Garay Pérez Matthew Ilveneff

202210036@tesco.edu.mx

Tecnológico de Estudios Superiores
de Coacalco

Ingeniería en Sistemas
Computacionales

Programación Lógica Y Funcional

Ing. Vivanco Benavides Luis Enrique

Entrega 29 de abril de 2025

3721

Introducción

El análisis exploratorio de datos (EDA, por sus siglas en inglés) constituye una etapa crítica en los procesos de investigación cuantitativa, ya que facilita la comprensión preliminar de la estructura de los datos, permite detectar patrones relevantes, identificar valores atípicos y sugerir relaciones entre variables (Tukey, 1977). En este contexto, el presente trabajo realiza un análisis detallado del conjunto de datos denominado "CPS1985", el cual recopila información sobre los salarios por hora de trabajadores en Estados Unidos en el año 1985.

Se inicia con la carga y exploración básica del conjunto de datos utilizando funciones como `dim`, `names` y `summary` en R, con el objetivo de entender la dimensión del dataset, conocer sus variables y observar sus estadísticas descriptivas. Posteriormente, se construyen histogramas para visualizar la distribución de los salarios, aplicando técnicas de personalización en el gráfico como ajuste del número de clases, colores, y bordes, para mejorar su claridad e interpretación (Wickham & Grolemund, 2016).

Además, se incorporan curvas de densidad sobre los histogramas, las cuales permiten suavizar la representación de la distribución y analizar su forma general sin depender de los límites de las clases del histograma. Se comparan diferentes niveles de suavizado mediante el parámetro `adjust`, lo que resulta útil para observar tendencias generales o detalles finos de la distribución. Con el objetivo de mejorar la simetría de la variable salario —dado que este tipo de variables económicas tienden a presentar una fuerte asimetría positiva— se aplica una transformación logarítmica ($\log(\text{wage})$). Esta transformación no solo mejora la visualización, sino que también prepara los datos para futuros análisis econométricos o de regresión, donde la normalidad de los residuos suele ser un supuesto importante (Wooldridge, 2013).

Finalmente, se añade una línea vertical correspondiente a la media de la distribución (original y transformada) para resaltar el valor promedio, permitiendo contrastarlo visualmente respecto a la forma general de la distribución de los datos. La combinación de histogramas,

curvas de densidad, transformación logarítmica y elementos gráficos auxiliares facilita un análisis exploratorio más completo, proporcionando una base sólida para cualquier inferencia estadística o modelado posterior (James, Witten, Hastie, & Tibshirani, 2013).

GOBIERNO DEL ESTADO DE MÉXICO | ESTADO DE MÉXICO | EDUCACIÓN | TESO

"2025. Bicentenario de la vida municipal en el Estado de México".

Control de prácticas y actividades para la asignatura:

PROGRAMACIÓN LÓGICA Y FUNCIONAL


Nombre del estudiante:	GAYÁN PÉREZ MATTHEW FLORES	
Grupo:	3721	
Nombre del profesor:	Luis Enrique Vivanco Benavides	
Nombre de la práctica o actividad	Fecha	Firma
Practica 6 Datasets	21 abril 2025	
Practica 7 SU Setting	23 abril 2025	
Practica 8 Gráficos	26 abril 25	
Avance revisión de datos	26 abril 25	

Desarrollo

Explorar El conjunto de datos CPS1985


Este código en R sirve para cargar y explorar un conjunto de datos llamado CPS1985, el cual proviene de un archivo CSV. Primero, la línea `cps1985 <- read.csv("CPS1985.csv", header=T)` lee el archivo "CPS1985.csv" y lo guarda en una variable llamada `cps1985`, considerando que la primera fila del archivo contiene los nombres de las columnas (por eso `header=T`). Luego, la función `dim(cps1985)` muestra las dimensiones del conjunto de datos, es decir, cuántas filas (observaciones) y columnas (variables) tiene. Después, con `names(cps1985)` se obtienen los nombres de todas las columnas del dataset, lo que nos ayuda

a saber qué tipo de información contiene. La función `summary(cps1985)` proporciona un resumen estadístico básico de cada columna, como la media, mediana, mínimos, máximos y cuartiles, lo cual da una idea general de los datos. Finalmente, `hist(cps1985$wage)` crea un histograma de la variable `wage` (salario), permitiendo visualizar cómo se distribuyen los salarios entre las personas registradas en el dataset.




Se sigue trabajando con el conjunto de datos `cps1985`. La primera línea, `attach(cps1985)`, sirve para "fijar" el dataset, lo que significa que se pueden usar directamente los nombres de las variables (como `wage`) sin tener que escribir `cps1985$wage` cada vez. Luego, en la línea `p <- hist(wage)`, se genera un histograma de la variable `wage` (salario), y ese histograma se guarda en el objeto `p`. Lo interesante viene después: con la función `text(p$mids, p$counts, labels=p$counts, adj=c(0.5,-0.5), cex=.5)`, se añaden etiquetas numéricas encima de cada barra del histograma, mostrando cuántas observaciones hay en cada intervalo. Aquí `p$mids` representa el punto medio de cada barra, y `p$counts` la cantidad de datos en cada una. La opción `adj` ajusta la posición del texto, y `cex` controla el tamaño del texto.

Se crea un histograma más personalizado para la variable wage, que representa el salario. Se utiliza la función `hist(wage, breaks=20, main=..., xlab=..., ylab=...)`. El parámetro `breaks=20` indica que el histograma tendrá 20 barras o divisiones, lo cual ayuda a ver la distribución de los salarios con mayor detalle. Luego, `main="Distribución del salario (Dólares por hora)"` establece el título principal del gráfico para que sea más descriptivo. Los parámetros `xlab="Salario"` y `ylab="Número de personas"` etiquetan el eje X y el eje Y respectivamente, haciendo que el gráfico sea más fácil de interpretar. En conjunto, este código no solo grafica la distribución de los salarios, sino que también mejora su presentación para que sea más claro y profesional.




Genera un histograma de la variable wage, pero esta vez con más personalización para mejorar su apariencia y claridad. Se usa `breaks=20` para dividir los datos en 20 intervalos o barras, permitiendo ver mejor cómo se distribuyen los salarios. El parámetro `main` agrega el título "Distribución del salario (Dólares por hora)", mientras que `xlab` y `ylab` etiquetan los ejes X y Y como "Salario" y "Número de personas", respectivamente. Además, `xlim=c(0,50)` ajusta el rango del eje X para que vaya de 0 a 50, enfocándose en el rango más relevante de los datos. La opción `col="white"` pinta las barras del histograma de blanco y `border="black"` pone bordes negros alrededor de cada barra, haciendo que el gráfico se vea más limpio y profesional.



Ahora se crea un histograma más detallado y visualmente trabajado de la variable wage, que representa los salarios. Primero, `hist(wage, breaks=20, freq=FALSE, ...)` genera el histograma con 20 divisiones, pero usando `freq=FALSE`, se cambia el eje Y para que muestre densidades en lugar de frecuencias, lo que facilita la comparación con curvas de distribución. El título del gráfico es "Distribución del salario (Dólares por hora)" y los ejes están etiquetados como "Salario" y "Número de personas". También se limita el rango del eje X de 0 a 50 (`xlim=c(0,50)`) y del eje Y de 0 a 0.15 (`ylim=c(0,0.15)`). Para darle estilo, las barras se colorean de marrón (`col="brown"`) con bordes amarillos (`border="yellow"`). Después, con `lines(density(wage), col="yellow", lwd=3)`, se dibuja una curva de densidad amarilla sobre el histograma, representando de manera suave cómo se distribuyen los salarios. Luego,

dibuja una línea azul en el valor promedio de los salarios transformados, permitiendo ver dónde se centra la mayoría de los datos.



Conclusiones

El análisis exploratorio realizado sobre el conjunto de datos "CPS1985" permitió identificar las principales características de la distribución salarial de los trabajadores en 1985. A través del uso de herramientas gráficas en R, como histogramas, curvas de densidad y transformaciones logarítmicas, se logró una comprensión más profunda de la estructura de los datos. La distribución original del salario mostró una fuerte asimetría positiva, evidenciando que la mayoría de las personas ganaba salarios bajos, mientras que unos pocos individuos obtenían salarios significativamente más altos.

La aplicación de la transformación logarítmica contribuyó a aproximar la distribución a una forma más simétrica, lo que facilita futuros análisis estadísticos como modelos de regresión o inferencia paramétrica, donde la normalidad de los datos es deseable. Además, la superposición de curvas de densidad permitió visualizar de manera más intuitiva la concentración de los datos y la presencia de posibles multimodalidades.

En resumen, el proceso de exploración gráfica y transformación de datos no solo aporta una visión descriptiva más rica, sino que también sienta las bases metodológicas para análisis

posteriores más robustos y precisos. Este tipo de análisis demuestra la importancia de una fase exploratoria detallada en cualquier estudio cuantitativo, ya que una buena comprensión inicial de los datos es clave para la correcta formulación de hipótesis y la elección de métodos estadísticos adecuados.

Referencias Bibliográficas

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An Introduction to Statistical Learning: With Applications in R. Springer.

Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.

Wickham, H., & Grolemund, G. (2016). R for Data Science: Import, Tidy, Transform, Visualize, and Model Data. O'Reilly Media.

Wooldridge, J. M. (2013). Introductory Econometrics: A Modern Approach (5th ed.). South-Western Cengage Learning.